

Выполните задания в Excel (в одном файле, но каждое на своём листе)

Задача 1

Используя процедуру **Генерация случайных чисел** из Пакета анализа, сделайте три класса нормальных выборок:

	мат.ожидание	дисперсия	объём	столбец
первая выборка	$a_1 = 1$	$\sigma^2 = 1$	$n_1 = 50$	А
вторая выборка	$a_2 = 2$	$\sigma^2 = 1$	$n_2 = 40$	В
третья выборка	$a_3 = 1$	$\sigma^2 = 4$	$n_3 = 60$	С

Выполните задания:

для каждой пары выборок проверить гипотезу $H_0 : a_1 = a_2$ при альтернативе $H_1 : a_1 \neq a_2$.
при уровне значимости $\alpha = 0,05$; Рассмотреть два случая: дисперсия известна и неизвестна.

для каждой пары выборок проверить гипотезу $H_0 : \sigma^2_1 = \sigma^2_2$ при альтернативе $H_1 : \sigma^2_1 \neq \sigma^2_2$
при уровне значимости $\alpha = 0,05$;

для пары выборок А и С проверить гипотезу $H_0 : a_1 = a_3$ при альтернативе $H_1 : a_1 \neq a_3$ при
уровне значимости $\alpha = 0,01$.

Решение

Для проверки каждой из гипотез необходимо рассчитать соответствующую статистику критерия и сравнить ее с соответствующим критическим значением.

Результаты решения задачи оформить в виде таблицы со следующими заголовками:

критерий	гипотеза	альтернатива	значение статистики критерия	критическое значение	вывод о принятии основной гипотезы
----------	----------	--------------	------------------------------------	-------------------------	---

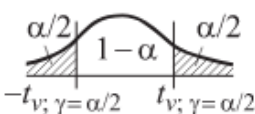
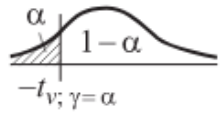
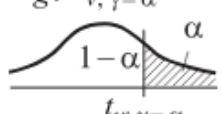
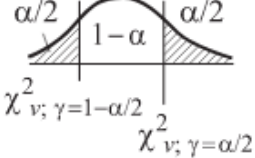
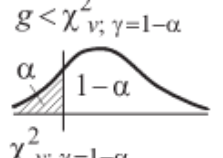
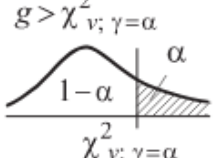
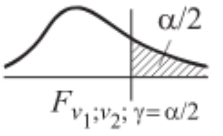
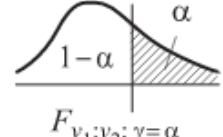
Для проверки гипотез согласия необходимо использовать указанные ниже варианты критериев, реализованные в Excel:

1. Используя инструмент анализа **Двухвыборочный t-тест с одинаковыми дисперсиями** из надстройки **Пакет анализа**, проверить гипотезу $H_0 : a_1 = a_2$ при альтернативе $H_1 : a_1 \neq a_2$ и уровне значимости $\alpha = 0,05$.

2. Используя инструмент анализа **Двухвыборочный t-тест с разными дисперсиями** из надстройки **Пакет анализа**, проверить гипотезу $H_0 : a_1 = a_3$ при альтернативе $H_1 : a_1 \neq a_3$ и уровне значимости $\alpha = 0,01$.

3. Используя инструмент анализа **Двухвыборочный f-тест** из надстройки **Пакет анализа**, рассмотреть гипотезу $H_0 : \sigma^2_1 = \sigma^2_2$ при альтернативе $H_1 : \sigma^2_1 \neq \sigma^2_2$ и уровне значимости $\alpha = 0,05$.

В качестве комментария ниже представлены некоторые стандартные критерии, позволяющие проверять гипотезы о значениях математических ожиданий и дисперсий нормальных генеральных совокупностей при независимых наблюдениях в выборке:

Проверяемая гипотеза H_0 и альтернативная гипотеза H_1	Информация о параметрах распределения	Статистика g , ее обозначение для каждого критерия	Распределение статистики g при справедливой гипотезе H_0	Критическая область
$H_0: m_x = m_0$ $H_1: m_x \neq m_0$	σ_x^2 неизвестно	$t = \frac{\bar{x} - m_0}{s_x / \sqrt{N}}$	t -распределение с $v = N - 1$ степенями свободы	$ g > t_{v; \gamma/2}$ 
$H_0: m_x = m_0$ $H_1: m_x < m_0$				$g < -t_{v; \gamma}$ 
$H_0: m_x = m_0$ $H_1: m_x > m_0$				$g > t_{v; \gamma}$ 
$H_0: \sigma_x^2 = \sigma_0^2$ $H_1: \sigma_x^2 \neq \sigma_0^2$	m_x неизвестно	$t = \frac{(N-1)s_x^2}{\sigma_0^2}$	χ^2 -распределение с $v = N - 1$ степенями свободы	$g < \chi_{v; \gamma/2}^2$ $g > \chi_{v; \gamma/2}^2$ 
$H_0: \sigma_x^2 = \sigma_0^2$ $H_1: \sigma_x^2 < \sigma_0^2$				$g < \chi_{v; \gamma}^2$ 
$H_0: \sigma_x^2 = \sigma_0^2$ $H_1: \sigma_x^2 > \sigma_0^2$				$g > \chi_{v; \gamma}^2$ 
$H_0: \sigma_{x_1}^2 = \sigma_{x_2}^2$ $H_1: \sigma_{x_1}^2 \neq \sigma_{x_2}^2$	m_{x_1}, m_{x_2} неизвестны	$F = s_1^2 / s_2^2$, где $s_1^2 = \max\{s_{x_1}^2, s_{x_2}^2\}$	F -распределение с v_1, v_2 степенями свободы, где v_1 и v_2 — число степеней свободы числителя и знаменателя	$g > F_{v_1; v_2; \gamma/2}$ 
$H_0: \sigma_{x_1}^2 = \sigma_{x_2}^2$ $H_1: \sigma_{x_1}^2 > \sigma_{x_2}^2$		$F = s_{x_1}^2 / s_{x_2}^2$		$g > F_{v_1; v_2; \gamma}$ 
$H_0: \sigma_{x_1}^2 = \sigma_{x_2}^2$ $H_1: \sigma_{x_1}^2 < \sigma_{x_2}^2$		$F = s_{x_2}^2 / s_{x_1}^2$		

Задача 2

Проверка гипотезы о нормальном распределении по критерию Пирсона χ^2

В типовой постановке задачи требуется, используя критерий Пирсона χ^2 , проверить гипотезу о том, что генеральная совокупность X распределена нормально (*The chi-square goodness of fit test*).

В случае проверки сложных гипотез мы задаем только форму распределения, и параметры распределения, в отличие от простой гипотезы, неизвестны, т.е. из выборки сначала нужно оценить эти неизвестные параметры, затем вычислить статистику χ^2 (как и для простых гипотез).

На новом листе в Excel смоделируйте нормально распределенную совокупность из 1000 элементов с помощью инструмента «Генерация случайных чисел» из пакета «Анализ данных», разместите эти данные в столбце А.

Генерация случайных чисел

Число переменных: 1

Число случайных чисел: 1000

Распределение: Нормальное

Параметры

Среднее = 12

Стандартное отклонение = 0,25

Случайное рассевание:

Параметры вывода

☒ Выходной интервал: \$A\$1

☐ Новый рабочий лист:

☐ Новая рабочая книга

OK Отмена Справка

Сформируйте случайную выборку из 200 элементов для этой совокупности с помощью инструмента «Выборка» из пакета «Анализ данных». Разместите эту выборку в столбце В.

Выборка

Входные данные

Входной интервал: \$A\$1:\$A\$1000

☐ Метки

Метод выборки

☐ Периодический

Период:

☒ Случайный

Число выборок: 200

Параметры вывода

☒ Выходной интервал: \$B\$1

☐ Новый рабочий лист:

☐ Новая рабочая книга

OK Отмена Справка

Используя критерий χ^2 (хи-квадрат) проверим, действительно ли выборка сделана из нормально распределенной генеральной совокупности.

В качестве точечных оценок математического ожидания и дисперсии примите соответствующие выборочные характеристики. Найдите их, используя «Описательную статистику» из пакета «Анализ данных». Разместите результаты расчета в столбцах C и D.

С помощью инструмента «Гистограмма» найдите опытные частоты n_i . Включать саму диаграмму не нужно, достаточно оставить только расчет разбиения в столбцах F,G.

Расчётные частоты p_i вычисляются через вероятности попадания нормально распределенной величины в соответствующий интервал:

$$p_i = \Phi\left(\frac{x_{i+1} - m}{\sigma}\right) - \Phi\left(\frac{x_i - m}{\sigma}\right),$$

где функция стандартного нормального распределения $\Phi(\cdot)$ вычисляется с помощью встроенной статистической функции НОРМ.РАСП(x , среднее значение m , стандартное отклонение σ , интегральный/весовой).

Аргументы функции НОРМ.РАСП: x - граница интервала, вводится адрес соответствующей ячейки; m и σ - вводятся абсолютные адреса характеристик, полученных с помощью «Описательной статистики»; значение Интегральный = (Истина) для функции распределения, в противном случае (Ложь) вычисляется плотность распределения.

В нашем случае таблицу вычисленных значений функции НОРМ.РАСП рассчитаем в колонке I. Вероятности p_i вычисляются как разности между значениями НОРМ.РАСП в текущей и предыдущей строках. В колонке J подсчитаем расчётные частоты $n \cdot p_i$ для $n = 200$ [например, $=(I3 - I2)*200$]

Для вычисления статистики χ^2 (хи-квадрат) в Excel есть функция ХИ2.ТЕСТ (интервал фактических данных, интервал ожидаемых данных). В качестве фактического интервала вводятся опытные частоты, в качестве ожидаемого – расчетные. Функция ХИ2.ТЕСТ возвращает **p-вероятность** того, что (при условии независимости) может быть получено такое значение статистики χ^2 , которое будет по крайней мере не ниже значения, рассчитанного по формуле

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(A_{ij} - E_{ij})^2}{E_{ij}}$$

Для вычисления этой вероятности, функцией ХИ2.ТЕСТ используется распределение χ^2 с соответствующим числом степеней свободы (df).

Сделайте вывод для данного примера о принятии гипотезы H_0 "Выборка взята из нормально распределенного набора данных" при уровне значимости 0,05 [=ЕСЛИ(0,05>J17;"Отклонить";"Нет оснований для отклонения")].

На новом листе Excel, используя критерий Пирсона χ^2 при уровне значимости 0,05, проверьте, согласуется ли гипотеза о нормальном распределении совокупности X с эмпирическим распределением выборки объема $N = 100$, полученной в модели семинара 2 характеристики «длительность пребывания» (колонка W).

Комментарий

При использовании критерия χ^2 количество опытных значений в каждом интервале должно быть не менее 5. Если в каком-то интервале их меньше, то интервалы объединяют. Например, если в промежутке от 4 до 6 оказалось три значения, а в промежутке от 6 до 8 – четыре, то вводится новый интервал от 4 до 8 с семью значениями. С учетом этого перестройте таблицу частот вручную. Например, в колонках Карман – Частота (F:G) будут данные, полученные автоматически, то в колонках Границы – Опытные частоты (I:J) данные надо пересчитать частично вручную.

При применении критерия χ^2 необходимо следить за тем, чтобы объем выборки n был достаточно большой, иначе будет неправомерно аппроксимация χ^2 -распределением распределения статистики χ^2 . Обычно считается, что для этого достаточно, чтобы наблюдаемые частоты (Observed) были больше 5. Если это не так, то малые частоты объединяются в одно или присоединяются к другим частотам, причем объединенному значению приписывается суммарная вероятность и, соответственно, уменьшается число степеней свободы χ^2 -распределения. Для того чтобы улучшить качество применения критерия χ^2 (увеличить его мощность), необходимо уменьшать интервалы разбиения (увеличивать количество степеней свободы), однако этому препятствует ограничение на количество попавших в каждый интервал наблюдений (нужно >5).

В случае сложной гипотезы, p -значение, которое мы сравниваем с уровнем значимости, рассчитывается с использованием χ^2 -распределения с $L-k-1$ степеней свободы, где k – количество оцениваемых параметров.

Если вероятность, того что случайная величина имеющая χ^2 -распределение с $L-k-1$ степенями свободы примет значение больше вычисленной статистики χ^2 , т.е. $\chi^2_{L-k-1} > \chi^2_0$ меньше уровня значимости, то нулевая гипотеза отклоняется.

Граница критической области – это квантиль распределения хи-квадрат, которая также может быть найдена с помощью встроенной функции ХИ2.ОБР.ПХ (вероятность, степени свободы). Аргумент «вероятность» – это уровень значимости ($\alpha = 0,05$), а «степени свободы» $df=k-l-1$ определяются как количество интервалов (здесь $k = 11$) за вычетом количества оцениваемых параметров (здесь два – μ и σ) и минус 1.